



سوالات نظری

سوال ۱:

- (آ) درست: در شبکه‌ی بیزی ساخته شده در الگوریتم Naive Bayes تنها بین متغیر کلاس و متغیرهای ویژگی یال داریم و بین متغیرهای ویژگی یالی وجود ندارد.
- (ب) درست: به عنوان مثال اگر در Spam/Ham Classification در داده‌های آموزشی یک کلمه را در یک کلاس ندیده باشیم ولی در داده‌های تست باشد، مدل احتمال وقوع آن کلمه را صفر و احتمال کل صفر می‌شود. در smoothing تصور می‌شود که هر کلمه را قبلاً دیده‌ایم و این مشکل رخ نمی‌دهد.
- (ج) نادرست: می‌توان از درخت‌های تصمیم برای مسائل Regression نیز استفاده کرد. (که به این دسته‌ی خاص، Regression Trees گفته می‌شود). در این حالت متغیرها به جای اینکه عضو چند کلاس خاص باشند (مقدار گسسته) می‌توانند مقادیر پیوسته بگیرند.
- (د) درست: با افزایش عمق، درخت پیچیده‌تر شده و می‌تواند جزئیات بیشتری را یاد بگیرد. در این حالت درخت علاوه بر الگوهای کلی، نویزهای داده‌های آموزشی را نیز یاد می‌گیرد و می‌گوییم Overfitting رخ داده.
- (ه) درست: اگر یک ویژگی تعداد زیادی مقدار یکتا داشته باشد، با تقسیم کردن بر اساس آن ویژگی به گره‌های فرزند زیادی می‌رسیم که هر کدام تنها شامل چند نمونه هستند. پس آن گره‌ها pure شده و آنتروپی کمی دارند. در این حالت آنتروپی شرطی نیز به صفر نزدیک شده و مقدار IG افزایش می‌یابد. بنابراین درخت تمایل دارد آن ویژگی را انتخاب کند. (برای حل این مشکل، از معیار Gain Ratio استفاده می‌شود).
- (و) نادرست: درخت تصمیم می‌تواند فضای ویژگی‌ها را با مجموعه‌ای از برش‌ها به نواحی چندوجهی مختلف تقسیم کند و مرزهای غیرخطی را مدل کند.
- (ز) درست: اگر مدل حتی روی داده‌های آموزشی هم عملکرد مناسبی نداشته باشد، یعنی مدل بیش از اندازه ساده بوده و نتوانسته الگوهای موجود در داده‌ها را به درستی یاد بگیرد. به این پدیده underfitting گفته می‌شود.
- (ح) نادرست: Hyper Parameter ها از روی داده‌های Validation یاد گرفته می‌شوند و اگر از داده‌های آموزشی برای این کار استفاده کنیم، overfitting رخ می‌دهد. (می‌توانیم هم خودمان Hyper Parameter ها را انتخاب کنیم).

سوال ۲:

(آ) ابتدا مقدار آنتروپی ریشه را محاسبه می‌کنیم:

$$\begin{aligned} H(Y) &= - \sum_{y_i} P(Y = y_i) \log_2 P(Y = y_i) \\ &= -[P(Y = \cdot) \log_2 P(Y = \cdot) + P(Y = \cdot) \log_2 P(Y = \cdot)] \\ &= -[\frac{5}{10} \log_2(\frac{5}{10}) + \frac{5}{10} \log_2(\frac{5}{10})] \\ &= 0.882 \end{aligned}$$

حال آنتروپی ریشه به شرط هر ویژگی را محاسبه می‌کنیم. فرمول کلی آنتروپی شرطی به صورت زیر است:

$$H(Y | X) = \sum_{x_j} P(X = x_j) \cdot H(Y | X = x_j)$$

با توجه به یکسان بودن توزیع داده‌ها برای دو ویژگی X_1 و X_2 ، محاسبات آن‌ها یکسان بوده و به همراه ویژگی X_2 به صورت خلاصه عبارتند از:

$$\begin{aligned} H(Y | X_1) &= H(Y | X_2) = \frac{4}{10} \left[-\frac{3}{4} \log_2 \left(\frac{3}{4} \right) - \frac{1}{4} \log_2 \left(\frac{1}{4} \right) \right] \\ &\quad + \frac{6}{10} \left[-\frac{4}{6} \log_2 \left(\frac{4}{6} \right) - \frac{2}{6} \log_2 \left(\frac{2}{6} \right) \right] \\ &\simeq 0.4(0.811) + 0.6(0.918) \simeq 0.875 \end{aligned}$$

$$\begin{aligned} H(Y | X_2) &= \frac{3}{10} [-1 \log_2(1)] + \frac{7}{10} \left[-\frac{4}{7} \log_2 \left(\frac{4}{7} \right) - \frac{3}{7} \log_2 \left(\frac{3}{7} \right) \right] \\ &\simeq 0.3(0) + 0.7(0.985) \simeq 0.689 \end{aligned}$$

در نهایت، مقدار بهره اطلاعاتی (Information Gain) برای هر ویژگی از رابطه $IG(X) = H(Y) - H(Y | X)$ به دست می‌آید:

$$\begin{aligned} IG(X_1) &= H(Y) - H(Y | X_1) = 0.882 - 0.875 = 0.007 \\ IG(X_2) &= H(Y) - H(Y | X_2) = 0.882 - 0.689 = 0.193 \\ IG(X_3) &= H(Y) - H(Y | X_3) = 0.882 - 0.875 = 0.007 \end{aligned}$$

بیشترین IG در ریشه از ویژگی X_2 (آیا ایمیل حاوی لینک مشکوک است؟) حاصل می‌شود. پس بهتر است درخت در ریشه بر اساس این ویژگی منشعب شود.

(ب) خیر؛ اگرچه می‌توانیم عمق درخت را تا جایی زیاد کنیم که دقت مدل روی داده‌های آموزشی ۱۰۰٪ شود، اما در این صورت overfitting رخ داده و درخت علاوه بر الگوهای اصلی، نویز داده‌های آموزشی را نیز یاد می‌گیرد و ممکن است عملکرد بدتری روی داده‌های تست داشته باشد.

(ج) معیار Gini Impurity به این شکل تعریف می‌شود:

$$G(Y) = \sum_{y_i} P(Y = y_i) \cdot (1 - P(Y = y_i)) = 1 - \sum_{y_i} P(Y = y_i)^2$$

$$G(Y | X) = \sum_{x_j} P(X = x_j) \cdot G(Y | X = x_j)$$

و به طور معادل به جای Information Gain هم مقدار Gini Gain به این شکل تعریف می‌شود:

$$\Delta G(X) = G(Y) - G(Y | X)$$

حال مشابه بخش قبل، محاسبات را انجام می‌دهیم:

$$G(Y) = 1 - [P(Y = ۰)^2 + P(Y = ۱)^2] = 1 - [(\frac{۷}{۱۰})^2 + (\frac{۳}{۱۰})^2] = ۰٫۴۲$$

و برای هر متغیر داریم:

$$G(Y | X_۱) = P(X_۱ = ۰) \cdot G(Y | X_۱ = ۰) + P(X_۱ = ۱) \cdot G(Y | X_۱ = ۱)$$

$$= (\frac{۴}{۱۰}) \cdot (1 - [(\frac{۳}{۴})^2 + (\frac{۱}{۴})^2]) + (\frac{۶}{۱۰}) \cdot (1 - [(\frac{۴}{۶})^2 + (\frac{۲}{۶})^2]) \simeq ۰٫۴۱۷$$

$$G(Y | X_۲) = P(X_۲ = ۰) \cdot G(Y | X_۲ = ۰) + P(X_۲ = ۱) \cdot G(Y | X_۲ = ۱)$$

$$= (\frac{۳}{۱۰}) \cdot (1 - [(1)^2]) + (\frac{۷}{۱۰}) \cdot (1 - [(\frac{۴}{۷})^2 + (\frac{۳}{۷})^2]) \simeq ۰٫۳۴۳$$

$$G(Y | X_۳) = P(X_۳ = ۰) \cdot G(Y | X_۳ = ۰) + P(X_۳ = ۱) \cdot G(Y | X_۳ = ۱)$$

$$= (\frac{۴}{۱۰}) \cdot (1 - [(\frac{۳}{۴})^2 + (\frac{۱}{۴})^2]) + (\frac{۶}{۱۰}) \cdot (1 - [(\frac{۴}{۶})^2 + (\frac{۲}{۶})^2]) \simeq ۰٫۴۱۷$$

مقادیر Gini Gain به این صورت می‌باشد:

$$\Delta G(X_۱) = G(Y) - G(Y | X_۱) = ۰٫۴۲ - ۰٫۴۱۷ = ۰٫۰۰۳$$

$$\Delta G(X_۲) = G(Y) - G(Y | X_۲) = ۰٫۴۲ - ۰٫۳۴۳ = ۰٫۰۷۷$$

$$\Delta G(X_۳) = G(Y) - G(Y | X_۳) = ۰٫۴۲ - ۰٫۴۱۷ = ۰٫۰۰۳$$

مشابه بخش بخش الف که از آنتروپی استفاده کردیم، در این بخش هم با استفاده از Gini Impurity دیدیم که بیشترین کاهش ناخالصی جینی (ΔG) به ازای متغیر $X_۲$ (آیا ایمیل حاوی لینک‌های مشکوک است؟) حاصل می‌شود. بنابراین باید این ویژگی را برای انشعاب در ریشه انتخاب کنیم.

سوال ۳:

(آ) برای اینکه این ایمیل در spam طبقه‌بندی شود، باید عبارت $P(Y = y) \prod_{i=1}^K P(W = w_i | Y = y)$ به ازای $y = \text{spam}$ بیشینه شود. این عبارت را به ازای دو حالت Y محاسبه می‌کنیم:

$$P(Y = \text{spam}) \prod_{i=1}^K P(W = w_i | Y = \text{spam}) = P(Y = \text{spam}) \left(\frac{1}{8}\right) \left(\frac{1}{4}\right) = \frac{1}{32} P(Y = \text{spam})$$

$$P(Y = \text{ham}) \prod_{i=1}^K P(W = w_i | Y = \text{ham}) = P(Y = \text{ham}) \left(\frac{1}{12}\right) \left(\frac{1}{6}\right) = \frac{1}{72} P(Y = \text{ham})$$

همچنین توجه داریم که $P(Y = \text{ham}) = 1 - P(Y = \text{spam})$. حال این نامساوی را حل می‌کنیم:

$$\begin{aligned} \frac{1}{32} P(Y = \text{spam}) &> \frac{1}{72} P(Y = \text{ham}) \\ \Rightarrow \frac{1}{32} P(Y = \text{spam}) &> \frac{1}{72} - \frac{1}{72} P(Y = \text{spam}) \\ \Rightarrow \frac{4+9}{4 \times 8 \times 9} P(Y = \text{spam}) &> \frac{1}{72} \\ \Rightarrow P(Y = \text{spam}) &> \frac{4 \times 8 \times 9}{8 \times 9 \times 13} \\ \Rightarrow P(Y = \text{spam}) &> \frac{4}{13} \\ \Rightarrow P(Y = \text{spam}) &> 0.308 \end{aligned}$$

(ب) می‌دانیم که:

$$P(W = w | Y = y) = \frac{\#\{W = w, Y = y\}}{\#\{Y = y\}}$$

باید تعداد کل کلمات در هر کلاس را مشخص کنیم:

$$\begin{aligned} \#\{Y = \text{spam}\} &= 4 + 6 = 10 \\ \#\{Y = \text{ham}\} &= 2 + 3 + 3 = 8 \end{aligned}$$

حال احتمالات خواسته شده را محاسبه می‌کنیم:

- $P(W = \text{just} | Y = \text{spam}) = \frac{\#\{W=\text{just}, Y=\text{spam}\}}{\#\{Y=\text{spam}\}} = \frac{2}{10} = 0.2$
- $P(W = \text{call} | Y = \text{ham}) = \frac{\#\{W=\text{call}, Y=\text{ham}\}}{\#\{Y=\text{ham}\}} = \frac{1}{8} = 0.125$
- $P(W = \text{offer} | Y = \text{ham}) = \frac{\#\{W=\text{offer}, Y=\text{ham}\}}{\#\{Y=\text{ham}\}} = \frac{1}{8} = 0.125$
- $P(Y = \text{spam}) = \frac{2}{5} = 0.4$

سوال ۴:

(آ) در این شبکه‌ی عصبی، هر نورون تنها می‌تواند یک ترکیب خطی از روی ورودی‌هایش بسازد؛ یعنی مثلاً نمی‌توانیم به طور مستقیم یک ورودی را به توان دیگری برسانیم یا از دو مقدار $\min$ بگیریم. بنابراین باید از توابع فعال‌سازی برای پیاده‌سازی این موارد استفاده کنیم:

- a^b : سعی می‌کنیم این تابع را به شکلی بنویسیم که بتوانیم آن را در شبکه محاسبه کنیم:

$$a^b = e^{(\ln a)b} = e^{e^{\ln(\ln a)b}} = e^{e^{\ln(\ln a) + \ln b}}$$


بنابراین می‌توانیم در لایه‌ی اول به کمک توابع فعال‌ساز، $\ln x_3$ و $\ln(\ln x_2)$ را بسازیم. سپس در لایه‌ی بعد، آنها را به یک نورون داده، با هم جمع زده و از تابع فعال‌ساز $\phi(x) = e^{e^x}$ استفاده می‌کنیم.

- $\min(a, b)$: برای محاسبه‌ی مینیمم، می‌توانیم از این رابطه استفاده کنیم:

$$\min(a, b) = a - \text{ReLU}(a - b)$$

اگر $a < b$ ، حاصل ReLU صفر می‌شود. اگر هم $a > b$ حاصل ReLU برابر با عبارت $a - b$ شده و مقدار نهایی b می‌شود. پس کافی است در یک لایه $\text{ReLU}(a - b)$ را ساخته و در لایه‌ی بعد $\min$ را محاسبه می‌کنیم.

بنابراین شبکه‌ی عصبی ما به این شکل خواهد بود (وزن‌های با مقدار ۰ رسم نشده‌اند):



و نورون‌ها نیز به این صورت می‌باشند:


نورون	وزن‌ها	بایاس	تابع فعال‌سازی	خروجی نهایی
$h_1^{(1)}$	$w_{11}^{(1)} = 1, w_{21}^{(1)} = 0, w_{31}^{(1)} = 0$	۰	$\phi(z) = z$	x_1
$h_2^{(1)}$	$w_{12}^{(1)} = 0, w_{22}^{(1)} = 1, w_{32}^{(1)} = 0$	۰	$\phi(z) = \ln(\ln z)$	$\ln(\ln x_2)$
$h_3^{(1)}$	$w_{13}^{(1)} = 0, w_{23}^{(1)} = 0, w_{33}^{(1)} = 1$	۰	$\phi(z) = \ln z$	$\ln x_3$
$h_1^{(2)}$	$w_{11}^{(2)} = 1, w_{21}^{(2)} = 0, w_{31}^{(2)} = 0$	۰	$\phi(z) = z$	x_1
$h_2^{(2)}$	$w_{12}^{(2)} = 0, w_{22}^{(2)} = 1, w_{32}^{(2)} = 1$	۰	$\phi(z) = e^{e^z}$	$x_2^{x_3}$
$h_1^{(3)}$	$w_{11}^{(3)} = 1, w_{21}^{(3)} = 0$	۰	$\phi(z) = z$	x_1
$h_2^{(3)}$	$w_{12}^{(3)} = 1, w_{22}^{(3)} = -1$	۰	$\phi(z) = \text{ReLU}(z)$	$\text{ReLU}(x_1 - x_2^{x_3})$
y	$w_{11}^{(y)} = 1, w_{21}^{(y)} = -1$	۰	$\phi(z) = z$	$\min(x_1, x_2^{x_3})$

(ب) برای forward pass، محاسبات را از گره‌های ورودی (فرزند) آغاز کرده و با حرکت به سمت راست، مقدار خروجی هر گره والد را بر اساس ورودی‌های آن محاسبه می‌کنیم تا در نهایت به خروجی سیستم (f) برسیم. برای backward pass نیز روند را برعکس کرده و از گره خروجی (ریشه) به سمت چپ حرکت می‌کنیم. در این مسیر، طبق قاعده‌ی زنجیره‌ای مشتق خروجی نسبت به هر متغیر را به دست می‌آوریم. به طور کلی اگر z تابعی از y و y تابعی از x باشد، طبق قاعده‌ی زنجیره‌ای داریم:

$$\frac{\partial z}{\partial x} = \frac{\partial z}{\partial y} \times \frac{\partial y}{\partial x}$$

بنابراین در الگوریتم forward pass، ابتدا به مشتق خروجی نسبت به خودش مقدار ۱ را نسبت می‌دهیم ($\frac{\partial f}{\partial f} = 1$). سپس با حرکت به سمت چپ، مشتق نهایی گره‌ی فرزند برابر خواهد بود با حاصل ضرب مشتق نهایی گره‌ی والد در مشتق محلی خود تابع نسبت به آن ورودی (که روی یال‌ها مشخص شده است).

اگر مقادیر forward pass را با رنگ آبی، مشتق‌های محلی هر تابع نسبت به ورودی‌هایش را با رنگ سبز و مشتق خروجی نهایی نسبت به هر گره را با رنگ قرمز نشان دهیم، گراف محاسباتی به همراه جزئیات گام به گام محاسبات به شکل زیر خواهد بود:



خروجی گره‌های ضرب اول و دوم را به ترتیب با v_1 و v_2 ، خروجی اولین گره جمع را با v_3 و خروجی دومین گره جمع (قبل از اعمال علامت منفی) را با v_4 نام‌گذاری می‌کنیم. در نهایت، با اعمال قاعده‌ی زنجیره‌ای از راست به چپ، مشتق خروجی نهایی نسبت به تک‌تک پارامترها و وزن‌های ورودی به صورت زیر محاسبه می‌شود:

$$\begin{aligned} \frac{\partial f}{\partial w_1} &= \frac{\partial f}{\partial v_1} \times \frac{\partial v_1}{\partial w_1} = \frac{e^{-1}}{(1+e^{-1})^2} \times x_1 = \frac{-e^{-1}}{(1+e^{-1})^2} \approx -0.197 \\ \frac{\partial f}{\partial x_1} &= \frac{\partial f}{\partial v_1} \times \frac{\partial v_1}{\partial x_1} = \frac{e^{-1}}{(1+e^{-1})^2} \times w_1 = \frac{2e^{-1}}{(1+e^{-1})^2} \approx 0.393 \\ \frac{\partial f}{\partial w_2} &= \frac{\partial f}{\partial v_2} \times \frac{\partial v_2}{\partial w_2} = \frac{e^{-1}}{(1+e^{-1})^2} \times x_2 = \frac{-2e^{-1}}{(1+e^{-1})^2} \approx -0.393 \\ \frac{\partial f}{\partial x_2} &= \frac{\partial f}{\partial v_2} \times \frac{\partial v_2}{\partial x_2} = \frac{e^{-1}}{(1+e^{-1})^2} \times w_2 = \frac{-3e^{-1}}{(1+e^{-1})^2} \approx -0.590 \\ \frac{\partial f}{\partial w_3} &= \frac{\partial f}{\partial v_3} \times \frac{\partial v_3}{\partial w_3} = \frac{e^{-1}}{(1+e^{-1})^2} \times 1 = \frac{e^{-1}}{(1+e^{-1})^2} \approx 0.197 \end{aligned}$$

سوال ۵:

(آ) در مسائل رگرسیون لجستیک (Logistic Regression)، استفاده از تابع زیان Binary Cross Entropy (BCE) نسبت به تابع خطای مربعات (SSE) ترجیح داده می‌شود. تابع هزینه SSE به صورت $J_{SSE} = \sum_{i=1}^n (y^{(i)} - \sigma(w^T x^{(i)}))^2$ تعریف می‌شود که گرادیان آن نسبت به بردار وزن برابر است با:

$$\nabla_w J_{SSE} = 2 \sum_{i=1}^n (\sigma(w^T x^{(i)}) - y^{(i)}) \cdot \sigma(w^T x^{(i)}) (1 - \sigma(w^T x^{(i)})) x^{(i)}$$

در حالی که همان‌طور که در بخش (ب) محاسبه شده است، گرادیان تابع BCE ترم مشتق سیگموئید را ندارد و ساده‌تر است: $\nabla_w J_{BCE} = \sum_{i=1}^n (\sigma(w^T x^{(i)}) - y^{(i)}) x^{(i)}$.

این تفاوت ساختاری دو مزیت مهم برای BCE ایجاد می‌کند. اول اینکه تابع BCE یک تابع محدب (convex) است؛ بنابراین تضمین می‌شود که تنها یک global minimum وجود دارد و الگوریتم Gradient Descent قطعاً به آن همگرا می‌شود، در حالی که ترکیب SSE با تابع فعال‌ساز sigmoid تابعی غیرمحدب ایجاد می‌کند که ممکن است در local minima گیر بیفتد. دوم اینکه فرآیند یادگیری در BCE دچار اشباع گرادیان (Gradient Saturation) نمی‌شود. به عنوان مثال، فرض کنید برای یک داده برجسب واقعی $y^{(i)} = 1$ باشد ولی مدل به اشتباه پیش‌بینی بسیار ضعیف نزدیک به صفر ($\sigma(w^T x^{(i)}) \rightarrow 0$) ارائه دهد. در این حالت، در تابع SSE ترم $(1 - \sigma(w^T x^{(i)}))^2$ به سمت صفر میل کرده و گرادیان را عملاً صفر می‌کند که باعث توقف یادگیری می‌شود؛ اما در تابع BCE این ترم خنثی شده و به دلیل ماهیت لگاریتمی، مدل جریمه بسیار سنگینی دریافت می‌کند تا وزن‌ها را سریع‌تر اصلاح کند.

(ب) اگر $z^{(i)} = w^T x^{(i)}$ و $\hat{y}^{(i)} = \sigma(z^{(i)})$ باشد، طبق قاعده‌ی زنجیره‌ای می‌توانیم مشتق گرادیان را حساب کنیم:

$$\frac{\partial J}{\partial w} = \sum_{i=1}^n \frac{\partial J}{\partial \hat{y}^{(i)}} \frac{\partial \hat{y}^{(i)}}{\partial z^{(i)}} \frac{\partial z^{(i)}}{\partial w}$$

هر مشتق را جداگانه محاسبه می‌کنیم:

$$\begin{aligned} J(w) &= -y^{(i)} \log(\hat{y}^{(i)}) - (1 - y^{(i)}) \log(1 - \hat{y}^{(i)}) \\ \Rightarrow \frac{\partial J}{\partial \hat{y}^{(i)}} &= \frac{-y^{(i)}}{\hat{y}^{(i)}} + \frac{1 - y^{(i)}}{1 - \hat{y}^{(i)}} = \frac{\hat{y}^{(i)} - y^{(i)}}{\hat{y}^{(i)}(1 - \hat{y}^{(i)})} \end{aligned}$$

$$\begin{aligned} \hat{y}^{(i)} &= \sigma(z^{(i)}) \\ \Rightarrow \frac{\partial \hat{y}^{(i)}}{\partial z^{(i)}} &= \sigma'(z^{(i)}) = \sigma(z^{(i)})(1 - \sigma(z^{(i)})) = \hat{y}^{(i)}(1 - \hat{y}^{(i)}) \end{aligned}$$

$$z^{(i)} = w^T x^{(i)} \Rightarrow \frac{\partial z^{(i)}}{\partial w} = x^{(i)}$$

بنابراین داریم:

$$\begin{aligned}\frac{\partial J}{\partial w} &= \sum_{i=1}^n \frac{\hat{y}^{(i)} - y^{(i)}}{\hat{y}^{(i)}(1 - \hat{y}^{(i)})} \hat{y}^{(i)}(1 - \hat{y}^{(i)})x^{(i)} \Rightarrow \frac{\partial J}{\partial w} = \sum_{i=1}^n (\hat{y}^{(i)} - y^{(i)})x^{(i)} \\ &\Rightarrow \nabla_w J(w) = \sum_{i=1}^n (\sigma(w^T x^{(i)}) - y^{(i)})x^{(i)}\end{aligned}$$

(ج) در این الگوریتم در هر گام وزن‌ها را تنها بر اساس یک نمونه از داده‌های آموزشی به روزرسانی می‌کنیم:

۱. ابتدا برای یک داده، بر اساس وزن‌های فعلی مقدار $\hat{y}^{(i)}$ را به این شکل محاسبه می‌کنیم:

$$\hat{y}^{(i)} = \sigma(w^T x^{(i)})$$

۲. وزن‌ها را در هر گام برای نمونه‌ی تصادفی i ام به این شکل به روزرسانی می‌کنیم (η نرخ یادگیری است):

$$\begin{aligned}w_{new} &= w_{old} - \eta \nabla_w J^{(i)}(w) \\ \Rightarrow w_{new} &= w_{old} - \eta (\sigma(w^T x^{(i)}) - y^{(i)})x^{(i)}\end{aligned}$$

(د) در صورتی که با یک مسئله‌ی دسته‌بندی سه‌کلاسه روبرو باشیم، ساختار مدل، تابع زیان و فرآیند آموزش به شرح زیر تغییر می‌کنند:

- به جای تابع sigmoid که یک خروجی مستقل تولید می‌کرد، لایه خروجی دارای ۳ نورون خواهد بود و از تابع Softmax برای تولید یک توزیع احتمالی بین کلاس‌ها استفاده می‌شود:

$$\hat{y}_k^{(i)} = \frac{e^{w_k^T x^{(i)}}}{\sum_{j=1}^3 e^{w_j^T x^{(i)}}}, \quad k \in \{1, 2, 3\}$$

- به جای یک بردار وزن واحد w ، برای هر کلاس یک بردار وزن جداگانه (w_k) خواهیم داشت. در نتیجه، کل پارامترهای مدل به صورت یک ماتریس وزن W نمایش داده می‌شوند که هر ستون آن مربوط به یک کلاس است.

- برچسب واقعی داده‌ها ($y^{(i)}$) دیگر یک عدد اسکالر (۰ یا ۱) نیست، بلکه تبدیل به یک بردار سه‌بعدی به صورت One-Hot می‌شود؛ به طوری که اگر نمونه متعلق به کلاس k باشد، مولفه‌ی k ام آن برابر با ۱ و سایر مولفه‌ها ۰ خواهند بود ($y^{(i)} \in \{0, 1\}^3$).

- به جای تابع هزینه BCE، از تابع Categorical Cross Entropy استفاده می‌کنیم:

$$J(W) = - \sum_{i=1}^n \sum_{k=1}^3 y_k^{(i)} \log(\hat{y}_k^{(i)})$$

سوال ۶:

(آ) اگر ورودی و خروجی داده‌های آموزشی را به صورت زوج‌های $(x^{(A)}, y^{(A)}), \dots, (x^{(D)}, y^{(D)})$ در نظر بگیریم و w هم بردار وزن‌ها باشد، در هر مرحله خروجی پرسپترون را به صورت $\hat{y}^{(i)} = \text{sign}(w^T x^{(i)})$ محاسبه می‌کنیم و اگر خروجی پرسپترون اشتباه بود (یعنی $\hat{y}^{(i)} \neq y^{(i)}$) آنگاه بردار وزن‌ها را طبق رابطه‌ی $w = w + \eta y^{(i)} x^{(i)}$ به‌روز می‌کنیم.

حال الگوریتم را برای ۴ داده‌ی داده شده اجرا می‌کنیم:

۱. داده‌ی A:

$$w = \begin{bmatrix} \bullet \\ \bullet \\ \bullet \end{bmatrix}, \quad x^{(A)} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} \Rightarrow \hat{y}^{(A)} = \text{sign}(w^T x^{(A)}) = \text{sign}(\bullet) = +1, \quad y^{(A)} = +1$$

۲. داده‌ی B:

$$w = \begin{bmatrix} \bullet \\ \bullet \\ \bullet \end{bmatrix}, \quad x^{(B)} = \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} \Rightarrow \hat{y}^{(B)} = \text{sign}(w^T x^{(B)}) = \text{sign}(\bullet) = +1, \quad y^{(B)} = +1$$

۳. داده‌ی C:

$$w = \begin{bmatrix} \bullet \\ \bullet \\ \bullet \end{bmatrix}, \quad x^{(C)} = \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix} \Rightarrow \hat{y}^{(C)} = \text{sign}(w^T x^{(C)}) = \text{sign}(\bullet) = +1, \quad y^{(C)} = -1$$

$$w = w + \eta y^{(C)} x^{(C)} \Rightarrow w = \begin{bmatrix} \bullet \\ \bullet \\ \bullet \end{bmatrix} + (1)(-1) \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix} \Rightarrow w = \begin{bmatrix} -1 \\ -1 \\ 2 \end{bmatrix}$$

۴. داده‌ی D:

$$w = \begin{bmatrix} -1 \\ -1 \\ 2 \end{bmatrix}, \quad x^{(D)} = \begin{bmatrix} 1 \\ -2 \\ -1 \end{bmatrix} \Rightarrow \hat{y}^{(D)} = \text{sign}(w^T x^{(D)}) = \text{sign}(-1) = -1, \quad y^{(D)} = -1$$

(ب) بردار نهایی وزن‌ها به صورت $w^T = [-1 \quad -1 \quad 2]$ می‌باشد. داریم:

$$\hat{y}^{(A)} = \text{sign}(w^T x^{(A)}) = \text{sign}(-1) = -1 \neq y^{(A)} = +1$$

$$\hat{y}^{(B)} = \text{sign}(w^T x^{(B)}) = \text{sign}(4) = +1 = y^{(B)} = +1$$

$$\hat{y}^{(C)} = \text{sign}(w^T x^{(C)}) = \text{sign}(-6) = -1 = y^{(C)} = -1$$

$$\hat{y}^{(D)} = \text{sign}(w^T x^{(D)}) = \text{sign}(-1) = -1 = y^{(D)} = -1$$

به جز داده‌ی آموزشی A ، تمام داده‌های دیگر درست طبقه‌بندی شدند؛ اما این لزوماً به معنای خطی جداناپذیر بودن داده‌ها نیست. ممکن است لازم باشد چند دور الگوریتم را روی تمام داده‌ها اجرا کنیم تا بتواند مرز تصمیم را به درستی پیدا کند.

(ج) بله، داده‌ها خطی جداناپذیر هستند. می‌بینیم که در هر ۴ نمونه‌ی داده شده، کلاس y برابر با $\text{sign}(f_2)$ است. از آنجا که تابع فعال‌سازی پرسپترون‌ها همان sign است، می‌توانیم بردار وزن‌ها را به صورت $w^T = \begin{bmatrix} 0 & 0 & 1 \end{bmatrix}$ بنویسیم. درستی این وزن‌ها را بررسی می‌کنیم:

$$\begin{aligned}\hat{y}^{(A)} &= \text{sign}(w^T x^{(A)}) = \text{sign}(1) = +1 &= y^{(A)} = +1 \\ \hat{y}^{(B)} &= \text{sign}(w^T x^{(B)}) = \text{sign}(2) = +1 &= y^{(B)} = +1 \\ \hat{y}^{(C)} &= \text{sign}(w^T x^{(C)}) = \text{sign}(-2) = -1 &= y^{(C)} = -1 \\ \hat{y}^{(D)} &= \text{sign}(w^T x^{(D)}) = \text{sign}(-1) = -1 &= y^{(D)} = -1\end{aligned}$$

می‌بینیم که تمام داده‌های آموزش به درستی طبقه‌بندی شدند.

سوال ۷:

(آ) نامساوی Jensen می‌گوید تابع $f : D \rightarrow \mathbb{R}$ روی دامنه‌ی D محدب است اگر و تنها اگر:

$$\forall x, y \in D, \forall 0 \leq \theta \leq 1 : f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y)$$

حال سعی می‌کنیم برای هر تابع داده شده نشان دهیم نامساوی جنسن برقرار است، یا مثال نقض بیاوریم:

• $f(x) = \sqrt{x}$ بر روی $[0, \infty)$
مقادیر $1, 9 \in [0, \infty)$ و $0 \leq t \leq 1$ را در نظر بگیرید:

$$f\left(\left(\frac{1}{4}\right)1 + \left(1 - \frac{1}{4}\right)9\right) = f(5) \simeq 2.24$$

$$\frac{1}{4}f(1) + \left(1 - \frac{1}{4}\right)f(9) = 2$$

$$f\left(\left(\frac{1}{4}\right)1 + \left(1 - \frac{1}{4}\right)9\right) \not\leq \frac{1}{4}f(1) + \left(1 - \frac{1}{4}\right)f(9)$$

مثال نقض آوردیم، پس نتیجه می‌گیریم که تابع $f(x)$ محدب نیست.

• $f(x) = x^2$ بر روی مجموعه‌ی کل اعداد حقیقی:
فرض می‌کنیم $0 \leq t \leq 1$ و x و y دو مقدار دلخواه باشند:

$$\begin{aligned} f(tx + (1-t)y) &\leq tf(x) + (1-t)f(y) \\ (tx + (1-t)y)^2 &\leq tx^2 + (1-t)y^2 \\ t^2x^2 + (1-t)^2y^2 + 2t(1-t)xy &\leq tx^2 + (1-t)y^2 \\ \bullet &\leq (t-t^2)x^2 + ((1-t) - (1-t)^2)y^2 - 2t(1-t)xy \\ \bullet &\leq t(1-t)(x^2 + y^2 - 2xy) \\ \bullet &\leq t(1-t)(x-y)^2 \end{aligned}$$

رابطه‌ی آخر همواره درست است. چون مقادیر x, y و t دلخواه بودند، به طور بازگشتی می‌توان نشان داد که نامساوی جنسن برای تمام مقادیر درست است. پس $f(x)$ محدب است.

(ب) می‌دانیم طبق آزمون مشتق دوم، اگر به ازای تمام نقاط دامنه $0 \leq f''(x)$ ، تابع محدب است و اگر به ازای تمام نقاط دامنه $0 \geq f''(x)$ ، تابع مقعر است.

• $f(x) = -\log(x)$ بر روی $(0, \infty)$
فرض می‌کنیم لگاریتم همان $\ln$ باشد (در غیر این صورت همه چیز تنها در یک ضریب ثابت مثبت ضرب می‌شود):

$$f'(x) = -\frac{1}{x}, f''(x) = \frac{1}{x^2} \Rightarrow \forall x \in (0, \infty) : f''(x) \geq 0$$

بنابراین از آزمون مشتق دوم نتیجه می‌گیریم که تابع f محدب است.

• $f(x) = x^4 - 2x^2$ بر روی مجموعه‌ی کل اعداد حقیقی

$$f'(x) = 4x^3 - 4x, f''(x) = 12x^2 - 4 : f''(0) = -4, f''(1) = 8$$

دیدیم که $f''(x)$ می‌تواند هم مقادیر مثبت و هم مقادیر منفی بگیرد. به طور دقیق‌تر، تابع f در بازه‌ی $(-\frac{1}{\sqrt{3}}, \frac{1}{\sqrt{3}})$ مقعر و در خارج از این ناحیه محدب است.

سوال ۸: (امتیازی)

(آ) اندازه‌ی فیلتر 2×2 هست، پس $F_w = F_h = 2$. ابتدا ابعاد خروجی را محاسبه می‌کنیم:

$$\text{output width} = \frac{W - F_w + 2P}{S_w} + 1 = \frac{4 - 2 + 2(1)}{1} + 1 = 5$$

$$\text{output height} = \frac{H - F_h + 2P}{S_h} + 1 = \frac{4 - 2 + 2(1)}{1} + 1 = 5$$

با افزودن padding ها، نقشه‌ی ورودی به این شکل خواهد بود:

$$X_{\text{padded}} = \begin{bmatrix} \bullet & \bullet & \bullet & \bullet & \bullet & \bullet \\ \bullet & 1 & 2 & 0 & 1 & \bullet \\ \bullet & 3 & 1 & 2 & 1 & \bullet \\ \bullet & 0 & 1 & 3 & 1 & \bullet \\ \bullet & 2 & 3 & 1 & 2 & \bullet \\ \bullet & \bullet & \bullet & \bullet & \bullet & \bullet \end{bmatrix}$$

هر درایه از نقشه‌ی خروجی نیز به این شکل محاسبه می‌شود:

$$O_{1,1} = \begin{bmatrix} \bullet & \bullet \\ \bullet & 1 \end{bmatrix} \odot \begin{bmatrix} 1 & -1 \\ \bullet & 1 \end{bmatrix} = (\bullet \times 1) + (\bullet \times -1) + (\bullet \times \bullet) + (1 \times 1) = 1$$

در نهایت اگر عملیات کانولوشن را به طور کامل انجام دهیم، نقشه‌ی خروجی به این شکل خواهد بود:

$$Y = \begin{bmatrix} 1 & 2 & 0 & 1 & 0 \\ 2 & 0 & 4 & 0 & 1 \\ -3 & 3 & 2 & 2 & 1 \\ 2 & 2 & -1 & 4 & 1 \\ -2 & -1 & 2 & -1 & 2 \end{bmatrix}$$

(ب) ۱. برای محاسبه‌ی ماتریس توجه، باید ماتریس Q را در ترانهاده‌ی K ضرب کنیم و سپس بر اساس بعد بردارها، آن را scale کنیم:

$$\frac{QK^T}{\sqrt{d_k}} = \left(\frac{1}{\sqrt{2}}\right) \begin{bmatrix} 1 & 2 \\ \bullet & 1 \end{bmatrix} \begin{bmatrix} \bullet & 1 \\ 1 & 1 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 2 & 3 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{3\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix}$$

۲. با اعمال Softmax روی حاصل بخش قبل داریم:

$$\text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) = \begin{bmatrix} \frac{e^{\frac{\sqrt{2}}{2}}}{e^{\frac{\sqrt{2}}{2}} + e^{\frac{3\sqrt{2}}{2}}} & \frac{e^{\frac{3\sqrt{2}}{2}}}{e^{\frac{\sqrt{2}}{2}} + e^{\frac{3\sqrt{2}}{2}}} \\ \frac{e^{\frac{\sqrt{2}}{2}}}{e^{\frac{\sqrt{2}}{2}} + e^{\frac{\sqrt{2}}{2}}} & \frac{e^{\frac{\sqrt{2}}{2}}}{e^{\frac{\sqrt{2}}{2}} + e^{\frac{\sqrt{2}}{2}}} \end{bmatrix} = \begin{bmatrix} 0.33 & 0.67 \\ 0.5 & 0.5 \end{bmatrix}$$

۳. در نهایت برای محاسبه‌ی خروجی نهایی، ماتریس حاصل را در V ضرب می‌کنیم:

$$Y = (\text{Softmax}(\frac{QK^T}{\sqrt{d_k}})) \times V = \begin{bmatrix} 0/33 & 0/67 \\ 0/5 & 0/5 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 1/33 & 2/34 \\ 1/5 & 2 \end{bmatrix}$$