



تمارین تئوری

سوال ۱:

پرسش‌های درست و نادرست:

- (آ) درست؛ سیاست استخراج‌شده تنها به مقادیر تقریبی ارزش حالت‌ها و ترتیب آنها بستگی دارد و نه مقادیر دقیق. بنابراین معمولاً پیش از اینکه ارزش‌ها به همگرایی دقیق برسند، سیاست بهینه به دست می‌آید.
- (ب) نادرست؛ الگوریتم Q-Learning همواره به مقادیر بهینه همگرا می‌شود، حتی اگر بر اساس سیاست بهینه عمل نکنیم.

(ج) درست؛ مدت زمان اجرای هر iteration از الگوریتم Value Iteration، از مرتبه‌ی $O(|S|^2|A|)$ ، و برای الگوریتم Policy Iteration، $O(|S|^3 + |S|^2|A|)$ می‌باشد. بنابراین اگر $|S| \approx |A|$ ، پیچیدگی زمانی هر iteration از دو الگوریتم از یک مرتبه‌ی یکسان می‌باشد.

(د) درست (در صورتی که مسئله دارای افق زمانی نامتناهی و $\gamma < 1$ باشد)؛ فرض می‌کنیم پاداش‌های جدید $R'(s, a, s') = R(s, a, s') + c$ باشند. طبق معادلات بلمن می‌دانیم که ارزش‌های بهینه به این صورت تعریف می‌شوند:

$$V^*(s) = \max_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V^*(s')]$$

و برای پاداش‌های جدید داریم:

$$V_{\text{new}}^*(s) = \max_a \sum_{s'} T(s, a, s') [R(s, a, s') + c + \gamma V_{\text{new}}^*(s')]$$

حدس می‌زنیم که ارزش تمام حالت‌ها به یک میزان ثابت افزایش می‌یابد $(V_{\text{new}}^*(s) = V^*(s) + \Delta)$. در این صورت داریم:

$$V_{\text{new}}^*(s) = \max_a \sum_{s'} T(s, a, s') [(R(s, a, s') + \gamma V^*(s')) + (c + \gamma \Delta)]$$

$$V_{\text{new}}^*(s) = \max_a \left(\sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V^*(s')] + \sum_{s'} T(s, a, s') (c + \gamma \Delta) \right)$$

$$V_{\text{new}}^*(s) = \max_a \left(\sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V^*(s')] + (c + \gamma \Delta) \right)$$

$$V_{\text{new}}^*(s) = V^*(s) + c + \gamma \Delta$$

فرض کرده بودیم که این افزایش به میزان Δ باشد. اکنون داریم:

$$\Delta = c + \gamma\Delta \implies \Delta = \frac{c}{1-\gamma}$$

از آنجا که طبق رابطه‌ی $\pi_{\text{new}}^*(s) = \arg \max_a \sum_{s'} T(s, a, s') [R'(s, a, s') + \gamma V_{\text{new}}^*(s')]$ برای پیدا کردن سیاست بهینه باید بین مقادیر مختلف بیشینه بگیریم، با اضافه شدن یک مقدار ثابت به تمام ارزش‌ها، سیاست بهینه تغییر نمی‌کند.

(ه) **نادرست:** از نظر شهودی، ضریب تخفیف را تعریف می‌کنیم تا reward های زودتر ارزش بیشتری داشته باشند. حال اگر دو MDP یکسان با ضریب تخفیف‌های متفاوت داشته باشیم (γ اولی بیشتر باشد)، الگوریتم دوم تلاش می‌کند مسیرهایی را انتخاب کند که در ابتدا reward بیشتری دارند، ولی الگوریتم اول کمتر به این موضوع اهمیت می‌دهد. بنابراین ممکن است سیاست بهینه‌ی این دو با هم متفاوت باشد.

(و) **درست:** در مسائل با افق محدود، تصمیم بهینه علاوه بر حالت فعلی، به اینکه چقدر زمان باقی مانده نیز بستگی دارد. به عنوان مثال اگر تنها یک گام باقی مانده باشد، باید پاداش همان مرحله را بیشینه کنیم، اما اگر مراحل بیشتری باقی مانده باشد، ممکن است اکشنی را انتخاب کنیم که پاداش فوری کمتری داشته باشد، اما کمک کند که در مراحل بعدی پاداش‌های بهتری بگیریم.

پرسش‌های با پاسخ کوتاه:

(آ) در روش‌های on-policy، سیاستی که در حال ارزیابی و بهبود آن هستیم، دقیقاً همان سیاستی است که از آن برای تعامل با محیط و جمع‌آوری داده‌های نمونه استفاده می‌شود. به عبارت دیگر، عامل از تجربیات حاصل از سیاست فعلی خود یاد می‌گیرد. اما در روش‌های off-policy، سیاستی که ارزیابی و بهینه‌سازی می‌شود با سیاستی که برای جمع‌آوری داده‌ها استفاده شده متفاوت است؛ در این حالت داده‌ها می‌توانند توسط یک سیاست مجزا (که حتی می‌تواند کاملاً تصادفی یا صرفاً برای اکتشاف محیط باشد) تولید شده باشند.

(ب) در روش‌های model-based، عامل ابتدا تلاش می‌کند یک مدل صریح و تجربی از رفتار محیط (شامل احتمال انتقال بین حالت‌ها و پاداش‌ها) را با روش‌های آماری یاد بگیرد و سپس با استفاده از روش‌های برنامه‌ریزی پویا مانند Value Iteration یا Policy Iteration آن را حل کند. در مقابل، در روش‌های model-free عامل نیازی به یادگیری یا دانستن مدل محیط ندارد، بلکه مستقیماً از طریق تعامل، تجربه و نمونه‌برداری از مسیرها، ارزش حالت‌ها یا خود سیاست را به‌روزرسانی و بهینه‌سازی می‌کند.

سوال ۲:

(آ) طبق الگوریتم Value Iteration در هر مرحله ارزش حالت‌ها را طبق رابطه‌ی زیر به‌روز می‌کنیم:

$$V_{new}(s) = \max_a \sum_{s', r} p(s', r | s, a) [r + \gamma V(s')]$$

بنابراین مرحله‌ی اول این الگوریتم برای حالت‌ها به این صورت می‌باشد (خانه‌ها را با $(row, column)$ نمایش داده و قرارداد می‌کنیم که $V_i(s)$ ارزش خانه s در سیاست π_i هست):

$$V_1(1, 1) = \max\{(\frac{1}{5}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))) + \frac{1}{5}(\frac{1}{9}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))) + \frac{1}{9}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))), \\ (\frac{1}{5}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))) + \frac{1}{5}(\frac{1}{9}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))) + \frac{1}{9}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))), \\ (\frac{1}{5}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))) + \frac{1}{5}(\frac{1}{9}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))) + \frac{1}{9}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))), \\ (\frac{1}{5}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))) + \frac{1}{5}(\frac{1}{9}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))) + \frac{1}{9}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9})))\} = 0$$

$$V_1(1, 2) = \max\{(\frac{1}{5}(-\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))) + 0, (\frac{1}{5}(-\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))) + 0, \\ (\frac{1}{9}(-\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))) + 0, 0\} = 0$$

$$V_1(1, 3) = 0$$

$$V_1(2, 1) = \max\{0, 0, 0, 0\} = 0$$

$$V_1(2, 2) = \max\{(\frac{1}{5}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))) + 0, (\frac{1}{5}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))) + 0, \\ (\frac{1}{9}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9}))) + 0, 0\} = \frac{1}{9}$$

$$V_1(2, 3) = 0$$

و در iteration دوم داریم:

$$V_2(1, 1) = \max\{0, 0, 0, 0\} = 0$$

$$V_2(1, 2) = \max\{\frac{1}{5}(-\frac{1}{9} + \frac{1}{9}(\frac{1}{9})) + 0, \frac{1}{5}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9})) + 0, \\ \frac{1}{5}(-\frac{1}{9} + \frac{1}{9}(\frac{1}{9})) + \frac{1}{9}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9})) + 0, \\ \frac{1}{5}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9})) + \frac{1}{9}(-\frac{1}{9} + \frac{1}{9}(\frac{1}{9})) + 0\} = \frac{6}{79}$$

$$V_2(1, 3) = 0$$

$$V_2(2, 1) = \max\{\frac{1}{5}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9})) + 0, \frac{1}{5}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9})) + 0, \\ \frac{1}{9}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9})) + 0, 0\} = \frac{7}{29}$$

$$V_2(2, 2) = \max\{\frac{1}{5}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9})) + 0, \frac{1}{5}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9})) + 0, \\ \frac{1}{5}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9})) + \frac{1}{9}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9})) + 0, \\ \frac{1}{5}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9})) + \frac{1}{9}(\frac{1}{9} + \frac{1}{9}(\frac{1}{9})) + 0\} = \frac{9}{405}$$

$$V_2(2, 3) = 0$$

(ب) در الگوریتم Temporal Difference Learning، به روزرسانی‌ها طبق این رابطه انجام می‌شود:

$$V_{new}^{\pi}(s) = (1 - \alpha)V^{\pi}(s) + (\alpha)(R(s, \pi(s), s') + \gamma V^{\pi}(s'))$$

بنابراین در تجربه‌ی $(1, 1) \rightarrow (1, 2) \rightarrow (1, 3)$ داریم:

$$(1, 1) \rightarrow (1, 2): V_{new}^{\pi}(1, 1) = (0/9)(0) + (0/1)(0 + 0/9(0)) = 0$$

$$(1, 2) \rightarrow (1, 3): V_{new}^{\pi}(1, 2) = (0/9)(0) + (0/1)(-10 + 0/9(0)) = -1$$

توجه داریم که برای تجربه‌ی دوم، باید از این مقادیر استفاده کنیم. در این تجربه داریم:

$$(1, 1) \rightarrow (1, 2): V_{new}^{\pi}(1, 1) = (0/9)(0) + (0/1)(0 + 0/9(-1)) = -0/9$$

$$(1, 2) \rightarrow (2, 2): V_{new}^{\pi}(1, 2) = (0/9)(-1) + (0/1)(0 + 0/9(0)) = -0/9$$

$$(2, 2) \rightarrow (2, 3): V_{new}^{\pi}(2, 2) = (0/9)(0) + (0/1)(+10 + 0/9(0)) = +1$$

(ج) به روزرسانی در الگوریتم SARSA به این صورت می‌باشد:

$$Q_{new}(s_t, a_t) = Q(s_t, a_t) + \alpha[R_{t+1} + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)]$$

مسیر اول:

$$(1, 1) \rightarrow (1, 2): Q_1((1, 1), \text{right}) = 0 + (0/1)[0 + 0/9(0) - 0] = 0$$

$$(1, 2) \rightarrow (1, 3): Q_1((1, 2), \text{right}) = 0 + (0/1)[-10 + 0/9(0) - 0] = -1$$

و مسیر دوم:

$$(1, 1) \rightarrow (1, 2): Q_1((1, 1), \text{right}) = 0 + (0/1)[0 + 0/9(-1) - 0] = -0/9$$

$$(1, 2) \rightarrow (2, 2): Q_1((1, 2), \text{right}) = -1 + (0/1)[0 + 0/9(0) - (-1)] = -0/9$$

$$(2, 2) \rightarrow (2, 3): Q_1((2, 2), \text{right}) = 0 + (0/1)[+10 + 0/9(0) - 0] = +1$$

(د) به روزرسانی در الگوریتم Q-Learning به این صورت می‌باشد:

$$Q_{new}(s_t, a_t) = Q(s_t, a_t) + \alpha[R_{t+1} + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)]$$

بنابراین این الگوریتم برای مسیر اول به این شکل خواهد بود:

$$(1, 1) \rightarrow (1, 2): Q_1((1, 1), \text{right}) = 0 + (0/1)[0 + 0/9 \max\{0, 0, 0, 0\} - 0] = 0$$

$$(1, 2) \rightarrow (1, 3): Q_1((1, 2), \text{right}) = 0 + (0/1)[-10 + 0/9 \max\{0, 0, 0, 0\} - 0] = -1$$

و برای مسیر دوم:

$$(1, 1) \rightarrow (1, 2): Q_1((1, 1), \text{right}) = 0 + (0/1)[0 + 0/9 \max\{0, -1, 0, 0\} - 0] = 0$$

$$(1, 2) \rightarrow (2, 2): Q_1((1, 2), \text{right}) = -1 + (0/1)[0 + 0/9 \max\{0, 0, 0, 0\} - (-1)] = -0/9$$

$$(2, 2) \rightarrow (2, 3): Q_1((2, 2), \text{right}) = 0 + (0/1)[+10 + 0/9 \max\{0, 0, 0, 0\} - 0] = +1$$

در گام اول از مسیر دوم که مقدار $Q_1((1, 1), \text{right})$ را برای بار دوم محاسبه می‌کنیم مقدار متفاوتی نسبت به الگوریتم SARSA تولید می‌شود ($-0/9$ در SARSA و 0 در Q-Learning). این اتفاق به این علت رخ می‌دهد که در Q-Learning هنگام محاسبه‌ی ارزش جدید، بین تمام اکشن‌ها بیشینه می‌گیریم. یعنی در SARSA مقدار جدید بر اساس اکشن انجام شده محاسبه می‌شود، و در Q-Learning بر اساس بهترین اکشن موجود.

(ه) با توجه به اینکه هنگامی که محرک وارد یک خانه می‌شود پاداش مربوط به آن را دریافت می‌کند، اگر پاداش هر گام را مشخص کنیم مسیرها به این صورت خواهند بود:

$$(1, 1) \xrightarrow{1} (1, 2) \xrightarrow{-1} (1, 3) \\ (1, 1) \xrightarrow{1} (1, 2) \xrightarrow{1} (2, 2) \xrightarrow{+1} (2, 3)$$

بنابراین ارزش این خانه‌ها به این صورت محاسبه می‌شود:

$$V^{\pi}(1, 1) = \frac{(0 + 0.9(-10)) + (0 + 0.9(0) + 0.9^2(10))}{2} = \frac{-9 + 8.1}{2} = -0.45 \\ V^{\pi}(1, 2) = \frac{(-10) + (0 + 0.9(+10))}{2} = \frac{-10 + 9}{2} = -0.5 \\ V^{\pi}(2, 2) = +10$$

هیچ تخمینی برای ارزش خانه‌هایی که هیچ‌گاه استیت آغازین یا میانی مسیری نبوده‌اند نداریم. (در اینجا خانه‌های $(3, 1)$ ، $(1, 2)$ و $(3, 2)$ به طور کلی در روش Direct Evaluation، هیچ اطلاعاتی بین همسایه‌ها منتقل نمی‌شود و ممکن است برای بعضی از خانه‌ها تخمینی نداشته باشیم. همچنین چون اطلاعات را ترکیب نمی‌کنیم، باید داده‌های بسیار زیادی داشته باشیم تا مقدار تخمینی از ارزش خانه‌ها به مقدار حقیقی نزدیک شود.

در مقابل در روش TD Learning، برای به‌روز کردن ارزش خانه‌ها از خانه‌های همسایه نیز استفاده می‌کنیم. بنابراین این روش می‌تواند زودتر و با نمونه‌های کمتر، تخمین بهتری به دست آورد.

سوال ۳:

این ادعا به طور کلی نادرست است و می‌توانیم برای آن مثال نقض بیاوریم. فرض کنید در یک MDP، مجموعه‌ی حالت‌ها $\{s_0, s_1, s_2, s_3\}$ باشد که s_3 حالت پایانی است، و مجموعه‌ی اکشن‌ها هم $\{a_0, a_1\}$ باشد. همچنین برای سادگی فرض می‌کنیم که ضریب تخفیف نداشته باشیم (یا به طور معادل $\gamma = 1$). همچنین توابع انتقال و پاداش‌ها به این صورت هستند:

• از حالت s_0 :

- با انتخاب اکشن a_0 قطعاً به حالت s_1 می‌رویم (پاداش = ۰).
- با انتخاب اکشن a_1 قطعاً به حالت s_2 می‌رویم (پاداش = ۰).

• از حالت s_1 :

- با انتخاب اکشن a_0 به حالت پایانی (s_3) می‌رویم (پاداش = ۱۰).
- با انتخاب اکشن a_1 به حالت پایانی (s_3) می‌رویم (پاداش = ۰).

• از حالت s_2 :

- با انتخاب اکشن a_0 به حالت پایانی (s_3) می‌رویم (پاداش = ۰).
- با انتخاب اکشن a_1 به حالت پایانی (s_3) می‌رویم (پاداش = ۱۰).

حال دو سیاست π_1 و π_2 را به این شکل تعریف می‌کنیم:

- π_1 : همواره در تمام حالت‌ها، اکشن a_0 را انتخاب می‌کند. در این حالت چون تمام اکشن‌ها و نتایج آنها قطعی هستند، می‌توانیم ارزش حالت‌ها را به سادگی مشخص کنیم:

$$V^{\pi_1}(s_0) = 10, \quad V^{\pi_1}(s_1) = 10, \quad V^{\pi_1}(s_2) = 0, \quad V^{\pi_1}(s_3) = 0$$

- π_2 : همواره اکشن a_1 را انتخاب می‌کند. برای این سیاست داریم:

$$V^{\pi_2}(s_0) = 10, \quad V^{\pi_2}(s_1) = 0, \quad V^{\pi_2}(s_2) = 10, \quad V^{\pi_2}(s_3) = 0$$

سیاست $\pi_3 = \frac{1}{4}\pi_1 + \frac{3}{4}\pi_2$ را تعریف می‌کنیم (یعنی در هر گام با احتمال $\frac{1}{4}$ طبق سیاست π_1 و با احتمال $\frac{3}{4}$ مطابق π_2 عمل می‌کنیم). ارزش حالت‌ها در این سیاست را طبق این رابطه محاسبه می‌کنیم:

$$V^{\pi_3}(s) = \sum_a \pi_3(a | s) \sum_{s'} T(s, a, s') [R(s, a) + V^{\pi_3}(s')]$$

بنابراین با توجه به این که $V^{\pi_3}(s_3) = 0$ است، داریم:

$$\begin{aligned} V^{\pi_3}(s_2) &= \frac{1}{4}(0) + \frac{3}{4}(10) = 5 \\ V^{\pi_3}(s_1) &= \frac{1}{4}(10) + \frac{3}{4}(0) = 5 \\ \Rightarrow V^{\pi_3}(s_0) &= \frac{1}{4}(5) + \frac{3}{4}(5) = 5 \end{aligned}$$

مشاهده می‌شود که $V^{\pi_3}(s_0) = 5$ ، اما طبق ادعای سوال باید مقدار آن ۱۰ باشد. بنابراین این ادعا نادرست است و برای آن مثال نقض آوردیم.

سوال ۴:

(آ) طبق رابطه Policy Evaluation ارزش حالت‌ها را به‌روز می‌کنیم:

$$V_{k+1}(s) = \sum_{s'} T(s, \pi(s), s') [R(s, \pi(s), s') + \gamma V_k(s')]$$

اجرای این بخش به این صورت می‌باشد:

$$V_1(A) = \frac{1}{4}(\frac{1}{4} + \frac{1}{5}(\frac{1}{2})) + \frac{1}{4}(\frac{1}{2} + \frac{1}{5}(\frac{1}{2})) = \frac{1}{4}$$

$$V_1(B) = \frac{1}{4}(\frac{1}{4} + \frac{1}{5}(\frac{1}{2})) + \frac{1}{4}(\frac{1}{2} + \frac{1}{5}(\frac{1}{2})) = \frac{1}{2}$$

$$V_1(C) = \frac{1}{4}(\frac{1}{4} + \frac{1}{5}(\frac{1}{2})) + \frac{1}{4}(\frac{1}{4}(\frac{1}{4} + \frac{1}{5}(\frac{1}{2})) + \frac{3}{4}(\frac{1}{4} + \frac{1}{5}(\frac{1}{2}))) = \frac{5}{5}$$

(ب) حال باید طبق رابطه‌ی زیر، Policy Improvement را انجام دهیم:

$$\pi_{i+1}(s) = \operatorname{argmax}_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V^{\pi_i}(s')]$$

بنابراین در این بخش داریم:

$$\begin{aligned} s = A \quad a = x : \frac{1}{4}(\frac{1}{4} + \frac{1}{5}(\frac{1}{2})) &= \frac{1}{4} \\ a = y : \frac{1}{4}(\frac{1}{2} + \frac{1}{5}(\frac{1}{2})) &= \frac{1}{4} \end{aligned} \Rightarrow \pi_1(A) = x$$

$$\begin{aligned} s = B \quad a = x : \frac{1}{4}(\frac{1}{2} + \frac{1}{5}(\frac{1}{2})) &= \frac{1}{4} \\ a = y : \frac{1}{4}(\frac{1}{4} + \frac{1}{5}(\frac{1}{2})) &= \frac{1}{2} \end{aligned} \Rightarrow \pi_1(B) = x$$

$$\begin{aligned} s = C \quad a = x : \frac{1}{4}(\frac{1}{4} + \frac{1}{5}(\frac{1}{2})) + \frac{3}{4}(\frac{1}{4} + \frac{1}{5}(\frac{1}{2})) &= \frac{1}{4} \\ a = y : \frac{1}{4}(\frac{1}{4} + \frac{1}{5}(\frac{1}{2})) &= \frac{1}{2} \end{aligned} \Rightarrow \pi_1(C) = x$$

(ج) ابتدا نشان می‌دهیم اگر π' به صورت حریصانه از π به دست آمده باشد، می‌توان نتیجه گرفت به ازای تمام حالت‌ها داریم $V^{\pi'}(s) \geq V^{\pi}(s)$.

اثبات. طبق تعریف داریم:

$$Q^{\pi}(s, \pi'(s)) = \max_a Q^{\pi}(s, a)$$

$$\Rightarrow Q^{\pi}(s, \pi'(s)) \geq Q^{\pi}(s, \pi(s))$$

$$\Rightarrow Q^{\pi}(s, \pi'(s)) \geq V^{\pi}(s)$$

همچنین می‌دانیم $Q^{\pi}(s, \pi'(s)) = \mathbb{E}_{\pi'}[R_{t+1} + \gamma V^{\pi}(S_{t+1})]$ بنابراین:

$$V^{\pi}(s) \leq \mathbb{E}_{\pi'}[R_{t+1} + \gamma V^{\pi}(S_{t+1})] \Rightarrow V^{\pi}(s) \leq \mathbb{E}_{\pi'}[R_{t+1} + \gamma Q^{\pi}(S_{t+1}, \pi'(S_{t+1}))]$$

و می‌توانیم این فرایند را به طور زنجیره‌ای ادامه دهیم:

$$V^\pi(s) \leq \mathbb{E}_{\pi'}[R_{t+1} + \gamma R_{t+2} + \gamma^2 V^\pi(s_{t+2})]$$

$\vdots$

$$V^\pi(s) \leq \mathbb{E}_{\pi'}[R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{n-1} R_{t+n} + \gamma^n V^\pi(s_{t+n})]$$

از آنجا که $0 \leq \gamma < 1$ ، با میل کردن $n \rightarrow \infty$ ، عبارت $\gamma^n V^\pi(s_{t+n})$ به صفر میل کرده و تنها عبارت‌های تابع پاداش باقی می‌مانند. به عبارتی:

$$V^\pi(s) \leq \mathbb{E}_{\pi'}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1}\right] = V^{\pi'}(s)$$

پس نشان دادیم به ازای هر حالت دلخواه، داریم $V^{\pi'}(s) \geq V^\pi(s)$. $\square$

حالا باید نشان دهیم که اگر حالت تساوی رخ دهد، سیاست π' بهینه است.

اثبات. اگر در روابط قسمت قبل تساوی قرار دهیم، داریم:

$$V^{\pi'}(s) = \max_a Q^\pi(s, a) = \max_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V^\pi(s')]$$

همچنین فرض کردیم $V^\pi(s) = V^{\pi'}(s)$. بنابراین:

$$V^{\pi'}(s) = \max_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V^{\pi'}(s')]$$

می‌بینیم که $V^{\pi'}(s)$ در رابطه‌ی بلمن صدق می‌کند. بنابراین π' سیاست بهینه است. $\square$

سوال ۵:

(آ) در مدل سازی MDP این بازی، فضای حالت ها به این صورت خواهد بود:

$$S = \{(\bullet, C), (۲, C), (۳, C), (۴, C), (۵, C), \text{Done}\}$$

که Done تنها حالت پایانی این MDP است.

(ب) بر اساس صورت سوال، فرض می کنیم تنها هنگامی که به حالت پایانی برویم پاداش می گیریم. این اتفاق در دو حالت رخ می دهد:

- اکشن stop: جمع اعداد هنوز کمتر از ۶ است، بنابراین به همان مقدار پاداش می گیریم.

$$R((n, C), \text{stop}, \text{Done}) = n$$

- اکشن draw: اگر در این حالت به Done برویم، یعنی مجموع مقادیر کارت ها بیشتر از ۵ شده، پس پاداشی نمی گیریم.

$$R((n, C), \text{draw}, \text{Done}) = \bullet$$

پاداش انتقال های دیگر صفر است.

(ج) ابتدا باید طبق رابطه ی $V_{k+1}(s) = \max_a \sum_{s', r} p(s', r | s, a)[r + \gamma V_k(s')]$ ارزش حالت ها را مدام بروز می کنیم تا مقادیر همگرا شوند.

از آنجا که در این مسئله $\gamma = ۱$ و همچنین توابع انتقال حالت ها یک گراف جهت دار بدون دور (DAG) تشکیل می دهند، می توانیم از روش استقرای عقب گرد (Backward Induction) استفاده کنیم. معادلات بلمن می گوید:

$$V^*(s) = \max_a \sum_{s'} T(s, a, s') [R(s, a) + \gamma V^*(s')]$$

بنابراین تنها با دانستن V^* همسایه های یک حالت، می توان V^* خودش را محاسبه کرد. بنابراین در این مسئله کافی است از حالت پایانی شروع کنیم و V^* ها را محاسبه کنیم:

$$\begin{aligned} s = \text{Done} \quad & V^*(\text{Done}) = \bullet \\ s = (۵, C) \quad & a = \text{stop} : ۱(۵ + ۱(\bullet)) = ۵ \\ & a = \text{draw} : \frac{1}{3}(\bullet + ۱(\bullet)) + \frac{1}{3}(\bullet + ۱(\bullet)) + \frac{1}{3}(\bullet + ۱(\bullet)) = \bullet \\ & \Rightarrow V^*((۵, C)) = ۵, \quad \pi^*((۵, C)) = \text{stop} \\ s = (۴, C) \quad & a = \text{stop} : ۱(۴ + ۱(\bullet)) = ۴ \\ & a = \text{draw} : \frac{1}{3}(\bullet + ۱(\bullet)) + \frac{1}{3}(\bullet + ۱(\bullet)) + \frac{1}{3}(\bullet + ۱(\bullet)) = \bullet \\ & \Rightarrow V^*((۴, C)) = ۴, \quad \pi^*((۴, C)) = \text{stop} \\ s = (۳, C) \quad & a = \text{stop} : ۱(۳ + ۱(\bullet)) = ۳ \\ & a = \text{draw} : \frac{1}{3}(\bullet + ۱(۵)) + \frac{1}{3}(\bullet + ۱(\bullet)) + \frac{1}{3}(\bullet + ۱(\bullet)) = \frac{۵}{۳} \\ & \Rightarrow V^*((۳, C)) = ۳, \quad \pi^*((۳, C)) = \text{stop} \end{aligned}$$

$$\begin{aligned}
s = (2, C) \quad a = \text{stop} : 1(2 + 1(\cdot)) &= 2 \\
a = \text{draw} : \frac{1}{3}(\cdot + 1(4)) + \frac{1}{3}(\cdot + 1(5)) + \frac{1}{3}(\cdot + 1(\cdot)) &= 3 \\
\Rightarrow V^*((2, C)) = 3, \quad \pi^*((2, C)) &= \text{draw} \\
s = (\cdot, C) \quad a = \text{stop} : 1(\cdot + 1(\cdot)) &= \cdot \\
a = \text{draw} : \frac{1}{3}(\cdot + 1(3)) + \frac{1}{3}(\cdot + 1(3)) + \frac{1}{3}(\cdot + 1(4)) &= \frac{10}{3} \\
\Rightarrow V^*((\cdot, C)) = \frac{10}{3}, \quad \pi^*((\cdot, C)) &= \text{draw}
\end{aligned}$$

(د) در Q-Learning، با دریافت هر سمپل (s, a, s', r) ، مقدار $Q(s, a)$ را طبق این رابطه بروز می‌کنیم:

$$Q_{\text{new}}(s, a) = (1 - \alpha)Q(s, a) + (\alpha)[\text{sample}]$$

بنابراین هنگامی که مقادیر همگرا شده و به حد نهایی خود رسیده‌اند داریم:

$$\begin{aligned}
Q(s, a) &= (1 - \alpha)Q(s, a) + (\alpha)[\text{sample}] \\
\Rightarrow (\alpha)Q(s, a) &= (\alpha)[\text{sample}] \\
\Rightarrow Q(s, a) &= \text{sample} \\
\Rightarrow Q(s, a) &= R(s, a, s') + \gamma \max_{a'} Q(s', a')
\end{aligned}$$

بنابراین در این بخش هم می‌توانیم با روش backward induction حد نهایی توابع Q را محاسبه کنیم:

$$\begin{aligned}
Q((5, C), \text{stop}) &= 5 + \cdot = 5, \quad Q((5, C), \text{draw}) = \cdot + \cdot = \cdot \\
Q((4, C), \text{stop}) &= 4 + \cdot = 4, \quad Q((4, C), \text{draw}) = \cdot + \cdot = \cdot \\
Q((3, C), \text{stop}) &= 3 + \cdot = 3, \quad Q((3, C), \text{draw}) = \cdot + 1(\max_{a'} \{Q((5, C), a')\}) = 5 \\
Q((2, C), \text{stop}) &= 2 + \cdot = 2, \quad Q((2, C), \text{draw}) = \cdot + 1(\max_{a'} \{Q((4, C), a')\}) = 4 \\
Q((\cdot, C), \text{stop}) &= \cdot + \cdot = \cdot, \quad Q((\cdot, C), \text{draw}) = \cdot + 1(\max_{a'} \{Q((2, C), a')\}) = 4
\end{aligned}$$

(ه) با مقادیر داده شده stop کنش حریصانه است (چون Q بیشتری دارد). در الگوریتم ε -greedy احتمال کنش‌های غیرحریصانه برابر است با:

$$P(\text{draw}) = \frac{\varepsilon}{|A|} = \frac{0.4}{2} = 0.2$$

و برای کنش حریصانه:

$$P(\text{stop}) = (1 - \varepsilon) + \frac{\varepsilon}{|A|} = (1 - 0.4) + \frac{0.4}{2} = 0.8$$

حال بر اساس مقادیر به دست آمده در بخش ج (ground truth)، مقدار مورد انتظار Q را محاسبه می‌کنیم:

$$\begin{aligned}
\mathbb{E}[Q^*((4, C), a)] &= P(\text{stop}) \cdot Q^*((4, C), \text{stop}) + P(\text{draw}) \cdot Q^*((4, C), \text{draw}) \\
&= 0.8(4) + 0.2(\cdot) = 3.2
\end{aligned}$$

(و) ابتدا regret هر گام را محاسبه می‌کنیم:

$$\text{regret}_1 = V^*((1, C)) - Q^*((1, C), \text{draw}) = \frac{10}{3} - \frac{10}{3} = 0$$

$$\text{regret}_2 = V^*((2, C)) - Q^*((2, C), \text{stop}) = 3 - 2 = 1$$

$$\text{regret}_3 = V^*((1, C)) - Q^*((1, C), \text{draw}) = \frac{10}{3} - \frac{10}{3} = 0$$

$$\text{regret}_4 = V^*((4, C)) - Q^*((4, C), \text{draw}) = 4 - 0 = 4$$

حال مقدار regret تجمعی را محاسبه می‌کنیم:

$$\text{regret}_{total} = \sum_{i=1}^4 \text{regret}_i = 0 + 1 + 0 + 4 = 5$$

سوال ۶:

(آ) از روی داده‌ها، مقادیر تخمینی $\hat{T}(s, a, s')$ را محاسبه می‌کنیم:

$$\begin{aligned}\hat{T}(X, a, X) &= 0, & \hat{T}(X, a, Y) &= \frac{2}{3} = 0.67, & \hat{T}(X, a, Z) &= \frac{1}{3} = 0.33, \\ \hat{T}(X, b, X) &= 1, & \hat{T}(X, b, Y) &= 0, & \hat{T}(X, b, Z) &= 0.\end{aligned}$$

$$\begin{aligned}\hat{T}(Y, a, X) &= 0, & \hat{T}(Y, a, Y) &= \frac{1}{3} = 0.33, & \hat{T}(Y, a, Z) &= \frac{2}{3} = 0.67, \\ \hat{T}(Y, b, X) &= 1, & \hat{T}(Y, b, Y) &= 0, & \hat{T}(Y, b, Z) &= 0.\end{aligned}$$

$$\begin{aligned}\hat{T}(Z, a, X) &= 0, & \hat{T}(Z, a, Y) &= 0, & \hat{T}(Z, a, Z) &= 1, \\ \hat{T}(Z, b, X) &= 1, & \hat{T}(Z, b, Y) &= 0, & \hat{T}(Z, b, Z) &= 0.\end{aligned}$$

(ب) مقدار تخمینی پاداش‌ها را محاسبه می‌کنیم:

$$\begin{aligned}\hat{R}(X, a, Y) &= 3, & \hat{R}(X, a, Z) &= 3, & \hat{R}(X, b, X) &= 1 \\ \hat{R}(Y, a, Z) &= 4, & \hat{R}(Y, a, Y) &= 4, & \hat{R}(Y, b, X) &= 2 \\ \hat{R}(Z, a, Z) &= 0, & \hat{R}(Z, b, X) &= 5\end{aligned}$$

برای حالت‌هایی که در داده‌ها موجود نیستند، تخمینی برای میزان پاداش نداریم. (البته چون در مدل ساخته شده احتمال انتقال آن حالت‌ها صفر در نظر گرفته شده، پس هیچ‌گاه رخ نمی‌دهند و مقدار پاداش آنها اهمیتی ندارد)

(ج) در بروزرسانی Value Iteration، ارزش جدید هر حالت را طبق رابطه‌ی زیر محاسبه می‌کنیم:

$$V_{new}(s) = \max_a \sum_{s', r} p(s', r | s, a) [r + \gamma V(s')]$$

همچنین برای هر حالت، اکشنی که ارزش بیشتر دارد را به عنوان کنش حریصانه انتخاب می‌کنیم:

$$V_1(X) = \max\left\{\frac{2}{3}(3 + 0.9(0)) + \frac{1}{3}(3 + 0.9(0)), 1(1 + 0.9(0))\right\} = 3 \Rightarrow \pi(X) = a$$

$$V_1(Y) = \max\left\{\frac{2}{3}(4 + 0.9(0)) + \frac{1}{3}(4 + 0.9(0)), 1(2 + 0.9(0))\right\} = 4 \Rightarrow \pi(Y) = a$$

$$V_1(Z) = \max\{1(0 + 0.9(0)), 1(5 + 0.9(0))\} = 5 \Rightarrow \pi(Z) = b$$

(د) بله؛ چون این MDP متناهی است و همچنین ضریب تخفیف $\gamma < 1$ دارد. الگوریتم Value Iteration تحت این شرایط همگرا می‌شود. (وجود حالت absorbing خلی به این موضوع وارد نمی‌کند.)